

Комплексный технический анализ архитектуры и ИИ-экосистемы проекта GRAPHIA: Технологический стек и интеграция больших языковых моделей

Введение и инфраструктурный контекст инициативы GRAPHIA

Проект GRAPHIA («Knowledge Graphs, AI Services and Next Generation Instrumentation for R&D in Social Sciences and Humanities»), финансируемый в рамках программы Европейского Союза Horizon Europe по соглашению о гранте № 101188018 с общим бюджетом 8,18 млн евро на период с января 2025 по декабрь 2027 года, направлен на ликвидацию структурного разрыва между массивами данных в социально-гуманитарных науках (SSH) и современными вычислительными методами их анализа¹. Исторически данные SSH характеризуются высокой фрагментацией, гетерогенностью, контекстуальной зависимостью и многоязычием, что ограничивает их машиночитаемость и снижает потенциал междисциплинарного использования³. Под руководством консорциума OPERAS и с участием ключевых исследовательских инфраструктур Европы (EHRI, E-RHIS, GGP, RESILIENCE), а также академических институтов, включая Болонский университет и Центр L3S, GRAPHIA формирует единую цифровую экосистему¹. Ключевым объектом разработки является первый всеобъемлющий граф знаний для социально-гуманитарных наук (SSH Knowledge Graph, SSH KG), объединяющий ранее изолированные архивы, социологические датасеты, библиографические реестры и объекты культурного наследия³. Технологический базис проекта опирается на глубокую интеграцию открытых методов семантического веба, гибридного графового моделирования, высокопроизводительных вычислительных сред и специализированных больших языковых моделей (LLM)³. Исследование архитектурных документов и результатов проекта позволяет детально восстановить полный стек применяемых технологий, программных каркасов и специализированных языковых моделей.

Архитектура графа знаний и базовый технологический стек

Фундамент платформы GRAPHIA строится на принципиальном отказе от централизованной агрегации данных в пользу распределенной федеративной модели графов знаний⁸. Такая модель обеспечивает семантическую связность автономных графов различных исследовательских институтов без необходимости принудительного

перемещения данных в единое хранилище⁸.

В основе представления данных лежит гибридная графовая архитектура, сочетающая стандарты Resource Description Framework Graph (RDF) и Labelled Property Graph (LPG)³. Стандарт RDF применяется для внешнего связывания данных, обеспечения интероперабельности в рамках принципов FAIR (Findable, Accessible, Interoperable, Reusable) и построения строгой онтологической схемы³. В то же время модель LPG внедряется на уровне вычислительных узлов для высокой скорости выполнения сложных графовых алгоритмов, анализа сетевых топологий и агрегации сущностей³.

Разрабатываемая Онтология GRAPHIA (GRAPHIA Ontology) задает общую модель данных (Common Data Model), фиксирующую provenance-метаданные, семантические трансформации и правила сопоставления разнородных источников⁸.

Для непрерывного сбора, извлечения и обогащения данных применяется Платформа сбора данных (Data Acquisition Platform) и специализированный программный каркас SSH Citation Index⁸. Систематический анализ показал, что традиционные методы библиографической обработки, созданные для дисциплин STEM, неприменимы к социально-гуманитарным наукам из-за специфики цитирования монографий, архивных источников и многоязычных сносок⁸. Разработанный фреймворк автоматизирует извлечение, индексацию и семантическое связывание цитирований из любых SSH-ресурсов, привлекая специализированные парсеры PDF-документов от команды OpenCitations¹.

Системная инфраструктура проекта разделена на два взаимодополняющих контура развертывания⁸. Для продуктивных веб-сервисов, API и контейнеризированных приложений применяется облачно-ориентированная платформа OKD (открытый дистрибутив Red Hat OpenShift)⁸. Вычислительно емкие задачи, включая дообучение и исполнение языковых моделей, а также масштабный аналитический обработчик графов, функционируют в средах высокопроизводительных вычислений (High-Performance Computing, HPC)⁸. Взаимодействие между элементами экосистемы регулируется Каркасом технической интероперабельности (Technical Interoperability Framework) через стандартизированные программные интерфейсы (API)⁸.

Архитектурный слой	Применяемые технологии и стандарты	Инфраструктурная роль в GRAPHIA
Семантическое моделирование	RDF, LPG, GRAPHIA Ontology (OWL/SKOS), SPARQL ³	Гибридное хранение и семантическая интеграция федеративных SSH-графов ³ .
Сбор и обработка цитирований	SSH Citation Index Framework, OpenCitations	Автоматическое извлечение, обогащение и

	PDF parsers ¹	индексация неколлапсируемых SSH-ссылок ¹ .
Вычислительная платформа	OKD (OpenShift/Kubernetes), HPC-кластеры ⁸	Контейнеризированное облачное развертывание микросервисов и HPC-вычисления ИИ ⁸ .
Слой интероперабельности	Technical Interoperability Framework, REST/GraphQL APIs, Zenodo ⁸	Стандартизация FAIR-протоколов и открытая публикация результатов ⁸ .

Экосистема больших языковых моделей: От моделей LLM4SSH до агентных систем

Центральным элементом технологического стека GRAPHIA выступает специализированная экосистема искусственного интеллекта, интегрирующая открытые, дообученные и прикладные модели больших языковых моделей (LLM)³. Использование унифицированных коммерческих LLM «из коробки» признано неэффективным из-за проблемы нехватки специализированных академических контекстов в обучающих выборках и высоких рисков нарушения суверенитета данных⁵.

Инициатива LLM4SSH

Ключевым технологическим продуктом в области ИИ является **LLM4SSH** — линейка открытых больших языковых моделей (open-source / open-weight LLMs), создаваемых специально для представления и обработки знаний в области социально-гуманитарных наук³. Архитектурно LLM4SSH проектируется как предметно-ориентированный аналог ChatGPT, адаптированный к исследовательской терминологии, историческим контекстам и многоязычным корпусам³.

Главные архитектурные требования к LLM4SSH включают высокую вычислительную производительность при сниженных затратах на инференс и возможность локального развертывания на частных серверах институтов или в инфраструктуре HPC⁸.

Локальный хостинг критически важен для соблюдения регламентов защиты персональных данных (GDPR) при работе с чувствительными исследовательскими материалами, такими как социологические опросы, данные о миграции или архивные свидетельства о военных конфликтах³. В задачи LLM4SSH входит концептуальное извлечение смыслов из неструктурированных текстов, автоматическая формализация знаний в графовые структуры и предоставление естественного интерфейса для ученых³.

Диалоговые интерфейсы и графовая навигация: Агентная система Quagga

Для обеспечения интуитивного доступа к знаниям SSH KG без необходимости составления вручную сложных SPARQL-запросов, компанией Odoma в рамках проекта GRAPHIA создана специализированная экосистема **Quagga** (Question Answering Over Graphs)⁸.

Архитектура Quagga строится на концепции Knowledge Graph Question Answering (KGQA) и включает три взаимодействующих компонента⁸:

1. **Quagga Agent:** Автономная агентная система, базирующаяся на открытых языковых моделях (open-weight LLMs) с применением архитектуры генерации с поисковым привлечением (Retrieval-Augmented Generation, RAG)⁸. Агент обрабатывает естественные вопросы пользователя на разных языках, извлекает семантический контекст и транслирует его в точные SPARQL-запросы к графу SSH KG и смежным базам данных (включая граф GoTriple)⁸.
2. **EXYGEN API (Explore Your Graphs Engine):** Программный сервис, генерирующий метаданные графа знаний для заземления (grounding) языковой модели⁸. EXYGEN предоставляет агенту актуальные структуры классов и предикатов целевого SPARQL-эндпоинта, предотвращая галлюцинации и ошибки синтаксиса при формировании запросов⁸.
3. **Quagga Benchmark:** Динамический краудсорсинговый набор данных, содержащий проверенные пары «вопрос на естественном языке — SPARQL-запрос»⁸. Охватив более 250 проверенных пар по 28 графам знаний SSH, данный бенчмарк служит основой для тонкой настройки и непрерывного валидирования моделей Quagga Agent⁹.

Прикладной ИИ-стек в специализированных пилотных сценариях

Применение технологий LLM в проекте GRAPHIA носит прагматичный характер и распределено по ряду исследовательских и промышленных пилотов, тестирующих различные нейросетевые архитектуры и промпт-инжиниринг⁸.

Индуктивный тематический анализ в TALLMesh

Разработанное Университетом Абертей (Abertay University) приложение TALLMesh представляет собой исследовательский инструмент на базе Python и графического фреймворка Streamlit для выполнения автоматизированного качественного тематического анализа по методологии Браун и Кларк (Braun & Clarke)¹⁰. Приложение связывает пользовательский интерфейс с API различных языковых моделей, поддерживая коммерческие провайдеры (OpenAI GPT-4o, Anthropic Claude, Azure OpenAI), а также открытые модели Llama-3, DeepSeek и Google Gemini¹¹. Для программной оптимизации инструкций и цепочек рассуждений в TALLMesh интегрирован фреймворк **DSPy**, а оценка точности отбора кодов осуществляется с помощью авторской метрики индуктивного тематического насыщения (Inductive Thematic Saturation, ITS)¹³.

Автоматическое индексирование в пилоте EHRI

В рамках пилота Европейской инфраструктуры архивов Холокоста (EHRI) исследуется

задача автоматизированного предметного индексирования (Subject Indexing) гетерогенных и многоязычных архивных описаний⁵. В ходе экспериментальных сравнений традиционные алгоритмы классификации и небольшие языковые модели уступили в точности крупным моделям уровня GPT-4o, Claude и Mistral⁵. Однако из-за специфики предметных рубрикаторов дальнейшее внедрение ориентировано на инфраструктуру LLM4SSH в режиме взаимодействия с экспертом (human-in-the-loop)⁵.

Документирование импакта в системе IMeTo

Совместный пилот Института литературных исследований Польской академии наук (IBL-PAN) и Познаньского центра суперкомпьютеров и сетей (PSNC) под названием IMeTo использует языковые модели, дообученные (fine-tuned) на специализированном корпусе польской национальной научной базы данных RADON¹⁰. Модель в автоматическом режиме анализирует тексты публикаций для выявления и классификации фактического социально-экономического эффекта научных исследований¹⁰.

Пространственный анализ в Genius Loci

Индустриальный пилот Genius Loci (платформа Genius Property) использует языковые модели для извлечения фактов и исторических контекстов из SSH KG¹⁰. Модели связывают архивные документы и этнографические исследования с кадастровыми и геопространственными данными, формируя динамические показатели привлекательности территорий¹⁰.

Фундаментальные модели симуляции социальных сетей

В рамках теоретических разработок, связанных с инструментарием GRAPHIA, внедряется фреймворк пост-обучения LLM с использованием обучения с подкреплением (Reinforcement Learning)¹⁵. В качестве сигналов обратной связи применяются наградные функции на основе графовых нейронных сетей (GNN), что позволяет адаптировать агентов к микро- и макро-симуляции поведения в социальных сетях¹⁵.

Инструмент / Пилот	Архитектура ИИ / Модели	Интеграционный механизм	Исследовательская функция
LLM4SSH (Ядро)	Открытые доменно-адаптированные LLM ³	Локальный инференс на HPC и OKD ⁸	Генерация ответов, извлечение знаний, базовый текстовый интерфейс SSH KG ³ .
Quagga System	Open-weight LLMs + RAG (Odoma) ⁸	EXYGEN API + SPARQL endpoints ⁸	Естественно-языковой перевод вопросов

			пользователей в SPARQL-запросы ⁸ .
TALLMesh	GPT-4o, Claude, Llama-3, DeepSeek, Gemini ¹¹	Streamlit GUI, REST APIs, DSPy framework ¹¹	Автоматизация качественного тематического анализа интервью и текстов ¹⁰ .
EHRI Pilot	Mistral, Claude, GPT-4o → транзит на LLM4SSH ⁵	Human-in-the-loop конвейеры ⁵	Многоязычное предметное индексирование сложных архивных массивов ⁵ .
IMeTo Pilot	Fine-tuned LLM (корпус RADON) ¹⁰	Standalone / Plugin микросервис ¹⁰	Извлечение показателей социального и экономического импакта исследований ¹⁰ .
Genius Property	Специализированные LLM-экстракторы ¹⁰	Извлечение сущностей из SSH KG ¹⁰	Привязка семантических контекстов к геопространственным данным ¹⁰ .

Системный синтез и перспективы развития технологического стека GRAPHIA

Анализ архитектурных решений проекта GRAPHIA демонстрирует зрелый инженерный подход к интеграции искусственного интеллекта в гуманитарные науки. Проект не ограничивается простым применением внешних API, а выстраивает комплексную инфраструктуру, решающую проблему изолированности данных SSH³.

Ключевым технологическим достижением является создание гибридной экосистемы, в которой математически строгая семантика гибридных графов знаний (RDF/LPG) объединена с гибкостью больших языковых моделей через механизмы RAG и агентные фреймворки уровня Quagga³. Разработка открытого семейства моделей LLM4SSH и ориентация на локальное развертывание в инфраструктурах OKD и HPC обеспечивают необходимый уровень суверенитета данных, конфиденциальности и соответствия законодательным нормам ЕС⁸. Реализуемый технологический стек создает

масштабируемый прецедент для последующей цифровизации европейских исследовательских инфраструктур, гарантируя сохранение глубины академического анализа в эпоху масштабного внедрения искусственного интеллекта³.

Works cited

1. GRAPHIA Project Launched in January 2025 - OpenCitations blog, <https://opencitations.hypotheses.org/3869>
2. GRAPHIA — University of Bologna - Research - Unibo, <https://www.unibo.it/en/research/projects-and-initiatives/horizon-europe/582/678/32175>
3. GRAPHIA - OPERAS, <https://operas-eu.org/projects/graphia/>
4. Knowledge Graphs, AI Services and Next Generation ... - CORDIS, <https://cordis.europa.eu/project/id/101188018>
5. The EHRI Use-Case for GRAPHIA: LLM-assisted Information, <https://lab.operas-eu.org/2025/08/18/the-ehri-use-case-for-graphia-llm-assisted-information-discovery-for-heterogeneous-multilingual-data/>
6. GRAPHIA - L3S Research Center, <https://www.l3s.de/research-at-l3s/all-projects/graphia/>
7. GRAPHIA: Home, <https://graphia-ssh.eu/>
8. Activities & Results - GRAPHIA, <https://graphia-ssh.eu/activities-and-results/>
9. Quagga - Home, <https://quagga.graphia-ssh.eu/>
10. Introducing GRAPHIA use cases - OPERAS Innovation Lab, <https://lab.operas-eu.org/2025/05/15/introducing-graphia-use-cases/>
11. sdptn/TALLMesh_multi_page: first commit - GitHub, https://github.com/sdptn/TALLMesh_multi_page
12. TALLMesh: a simple application for performing Thematic Analysis, <https://arxiv.org/pdf/2504.13892>
13. (PDF) Codebook Reduction and Saturation: Novel observations on, https://www.researchgate.net/publication/389694084_Codebook_Reduction_and_Saturation_Novel_observations_on_Inductive_Thematic_Saturation_for_Large_Language_Models_and_initial_coding_in_Thematic_Analysis
14. Genius Loci & GRAPHIA: Giving Shape to the Question “Where?”, <https://lab.operas-eu.org/2025/08/29/genius-loci-graphia-giving-shape-to-the-question-where/>
15. GRAPHIA: Harnessing Social Graph Data to Enhance LLM-Based, <https://aclanthology.org/2026.acl-long.322/>
16. GRAPHIA: Harnessing Social Graph Data to Enhance LLM-Based, <https://arxiv.org/abs/2510.24251>